六分子关联泛函的数据准备

本周证据归档、可编辑流程与采样预算

2026-10-22 至 2026-10-28

研究问题。以水、氨、甲烷、乙烯、乙烷和二氧化碳为对象，能否先通过机器学习势与可核查的统计采样获得密度及两体关联，再训练一个对分子与状态变化有泛化能力的 c_1/c_2 模型？本文将本周两个仓库的准备工作和后续预算放在同一条路径中。文献各自的采样单位不同，本报告先算基础轨迹与目标验证，再列状态覆盖缺口。

目前可支持的判断。六分子教师单点和学生势的留出集误差有记录；OFF23 水轨迹已有逐帧目标能量与权重诊断。它们证明可做数据管道探索，但尚未证明六种分子的目标体系密度、$g(r)$、c_1 或 c_2 已达训练标签质量。尤其只有一条 300 K、384 水分子的 OFF23 长轨迹；没有与其对应的独立 POLAR 长轨迹。

本报告建议。先为六种分子建立基础源轨迹；在目标能量、重叠和误差允许的范围内，温度及外场通过后处理复用同一批构型。先做独立副本与教师验证，再按缺口补密度锚点。后文 $1\,\mathrm{ns}$ 是预算情景，不是独立样本数或已完成计算。

版本。本次证据快照：test 65a0423，symmetrix-polar 68f08d1。后续仓库变更需重新核对对应证据。所有图的数值源及脚本随归档保存。

1 科学背景：从密度与关联到泛函

1.1 PNAS：带外场的密度用于学习 c_1

Bui 与 Cox 将不同流体和相互作用势下的随机外场 MD 密度用于训练一体直接关联泛函。原文使用单独的流体 / 势模型，而不是已经得到跨分子的统一泛函。其水与二氧化碳例子使用已有机器学习势，在平面随机外势下生成密度；每个流体和势的训练数据约 500–1000 个独立模拟，生产时间至少 $1\,\mathrm{ns}$，时间步长 $0.5\,\mathrm{fs}$。外力施加在定义的分子中心位点，化学势作为每次模拟的潜变量学习 [1，材料与方法]。

对应平衡关系可写成

$$c_1(z;[\rho],T) = \ln[\rho(z)\Lambda^3] + \beta V_{\mathrm{ext}}(z) - \beta\mu, \qquad \beta = (k_B T)^{-1}. \tag{1}$$

因此只统计密度尚不能无条件给出绝对 c_1；还需外场、温度、化学势与理想参考。固定 N 的 MD 可以采用与 PNAS 一致的潜变量策略，但要明确密度变量、有限尺寸和参考基准。

1.2 PRL：体相关联监督 F_{ex} 的二阶导数

Dijkman 等在均匀 Lennard–Jones 体相中用 GCMC 采样 $g(r)$，通过 OZ 方程得到体相 c_2，训练自由能网络的 Hessian；该分支并非将每个外场的 c_1 真值直接作为监督。其对照模型则使用非均匀密度对应的一阶导数数据 [2]。

$$h(r) = g(r) - 1, \quad S(k) = 1 + \rho_b \hat{h}(k), \quad \hat{c}_2(k) = \frac{\hat{h}(k)}{1 + \rho_b \hat{h}(k)}. \tag{2}$$

式子适用于均匀、各向同性、单组分且定义相匹配的标量密度。水的氧位点与分子质心是不同变量；取向分辨或不均匀体系需对应的多分量 / 位置依赖关系。原文为 Lennard–Jones 模型而非本项目六分子的精度认证。

1.3 JCTC：显式位置–取向密度

Yang 等研究超临界 CO_2，以单方向位置及两个取向角描述分子密度，并使用取向相关的 c_1 神经算子；这与本周主要做的分子质心密度不同。其 GCMC 支持信息记载单次模拟约 4×10^6 个试探步平衡、5×10^7 个试探步生产；主文采用 8 个温度和 10 个化学势条件，支持信息描述给定外场下 320 组密度剖面 [7]。这些 MC 试探步、MD 轨迹帧与独立剖面不能混算。六分子包含水等非线性分子时，取向变量及对称性也需要重新定义。

1.4 文献数量与本工作预算的关系

PNAS的每流体 / 势 500–1000 个外场模拟，是独立生成数据的论文设置；PRL 的 800 个体相密度–关联训练样本来自 Lennard–Jones 体相 GCMC；JCTC 的 320 组剖面来自其 CO_2 GCMC 设置。它们对应不同的体系、温度、采样和标签，并不要求本项目无条件重做同数目的模拟。本报告先探索复用基础轨迹，但需以目标观测量的误差与重叠证据确认实际能复用多少条件。

2 整体研究流程及当前状态

图 1 从已核对的文献和六分子教师数据出发，将势函数、采样、标签、统一模型及物理性质贯通。红色节点表示待完成或未验证；黄色节点表示已有局部结果但尚不足以支持下一层结论。PDF 是可阅读的静态视图；同目录 HTML 可拖动节点、修改文字和状态，导出 JSON 或 SVG。

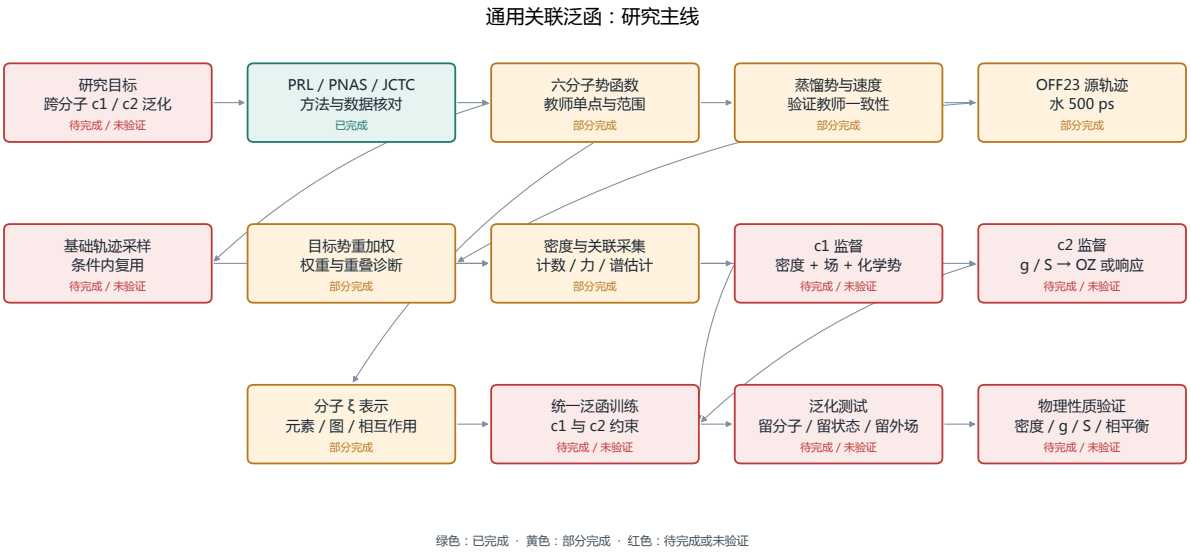


Figure 1: 六分子数据到关联泛函的研究流程。节点颜色是截至本次归档的状态，不代表永久定论；输入、输出与尚缺证据见在线工作台节点说明。

3 本周结果：势函数与重加权

3.1 六分子教师与学生

六分子教师烟测覆盖 H_2O、NH_3、CH_4、C_2H_4、C_2H_6 和 CO_2，每种 8 个构型、每盒 12 个分子。随机构型有不合理近接，CO_2 最大力约 $37.5\,\mathrm{eV/Å}$，故只能证明单点与写出流程可运行，不能当作平衡结构集 [3]。

Plan D 的已有留出集对教师能量/力结果由源 JSON 汇总，图 2 分别画出六种分子的体相子集。总留出集为 3465 帧、总能量 MAE 约 $1.12\,\mathrm{meV/atom}$、力分量 MAE 约 $7.75\,\mathrm{meV/Å}$；样本由不同状态混合，不能将其误认成独立实验误差。CO_2 体相力误差最大，约 $23.62\,\mathrm{meV/Å}$。电荷 / 偶极头的已有评价和主干 E/F 评价涉及不同数据与功能，尚需完整力场耦合、外场、动力学稳定性和外推验证。

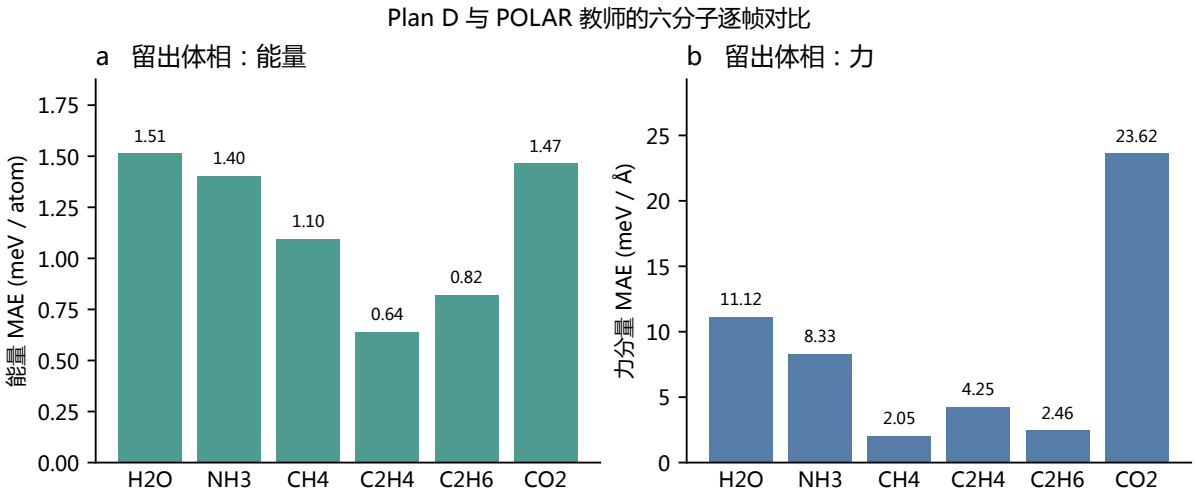


Figure 2: Plan D 相对 POLAR 教师的留出体相逐帧误差，按分子分组。数值从归档的 `teacher_student_by_species.json` 读取；这不是相对 DFT 或实验的误差。

3.2 数据规模及已发现的限制

源仓 2026-10-25 的重建记录报告 26,841 个已保留构型，其中 23,376 训练、3465 验证；每种分子的体相帧数为 H_2O 4998、NH_3 4574、CH_4 4065、C_2H_4 3432、C_2H_6 3126、CO_2 4480，气相每种 361 帧 [4]。这些是 E/F 蒸馏构型，并非 26,841 个独立 c_1/c_2 标签。仓库内 `data/split_manifest.json` 是较早的 15,641 帧快照，与后来的重建报告不同；新清单和大数据文件能否获取须另行核验。

同一审计记录指出，部分早期状态只有 $0.6\,\mathrm{ps}$、每 $6\,\mathrm{fs}$ 存一帧；平衡、相关性、重复种子及小盒尺寸需要重查 [5]。不把这些帧数直接换算为有效独立样本，也不以训练 / 验证误差替代对目标物理性质的验证。

3.3 一条水轨迹的权重与质心密度

OFF23 用 NVT 在 300 K、384 水分子、1 fs 时间步运行，已有 500 ps 生产轨迹；501 个时刻重新计算 OFF23/POLAR 整盒能量。全部 501 帧的经验权重 ESS 为 2.35，最大单帧权重 59.6%；图 3(a) 显示实际权重。删除生产前 20 帧后仍为约 1.20，但这 20 ps 是基于现有分块现象选出的敏感性切点，不是平衡的证明。OFF 引擎与重算能量去常数后标准差约 $0.030\,\mathrm{eV}$，粒子坐标和日志精度、邻居表与精度路径尚待核对。

图 3(b) 给出同一批帧的水质心密度：OFF23 等权、POLAR 目标重加权估计及其平滑版。平滑缩小了前后半段差异，但会改变空间分辨率，不能由此断定更准确。条件能量差近似在稀疏区产生超出已有帧支持的峰，故尚不能替代目标参考。z 向分层且质心对统计在 6–8 Å 均值约 1.56，不能直接对其套用均匀体相标量 OZ。

避免跨仓误读。`symmetrix-polar` 的某些旧页面把 OFF23 帧上计算的 $U_{\mathrm{POLAR}} - U_{\mathrm{student}}$ 评分称为生产尺寸学生自采样 ESS，并据此判定失败；但这 501 帧来自 OFF23，不是学生势。该分母不匹配采样分布；此数只能作为评分集中度，不能判定学生自采样的重叠。已有 $50\,\mathrm{ps}$ 学生自采样

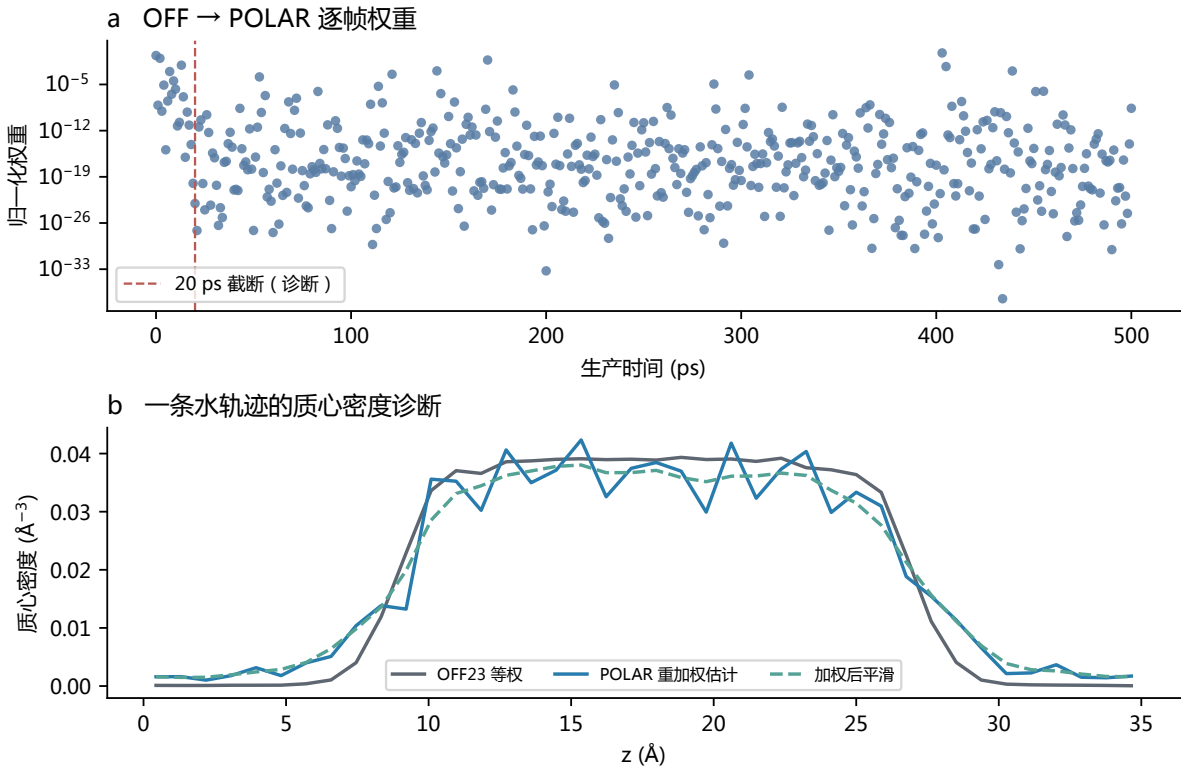


Figure 3: 同一条水轨迹的权重和质心密度诊断。加权曲线是目标估计，没有独立 POLAR 密度真值；虚线仅表示后处理平滑。

试验可作为独立的小规模线索，但其单轨迹、平衡和相关性不足以证明生产质量。不可把旧页绝对结论搬到本报告。

4 单体系采样流程与估计器

图 4 给出从体系定义到独立物性对照的顺序。对密度格 k，当前每帧可用的质心计数写为

$$A_k^{\rho}(x) = \frac{N_k^{\mathrm{COM}}(x)}{V_k}, \qquad \widehat{\rho}_{H,k} = \frac{\sum_i q_i A_k^{\rho}(x_i)}{\sum_i q_i}. \tag{3}$$

对体相关联，A_k^{g} 由每帧落在距离壳层内的无序质心对数除以匹配的均匀参考对数。二者分别提供一体密度与两体统计；改变 A 不改变同一组 q 的 Kish ESS。均匀参考、分子身份、有限 N、周期边界和力的定义都应保存到数据接口。

后续可比较原始计数、目标力辅助密度、谱函数关联统计与不同频率的 q / qA 估计，评价指标为误差、覆盖、相关时间与 GPU 调用成本。当前文件不包含逐原子 POLAR 力，尚未实施目标力估计。已有 qA 分子每 5 帧抽样敏感性试验在这条轨迹上高度依赖抽帧起点，不能推广为任何更长采样都失败。

5 六分子采样预算：基础轨迹复用优先

5.1 预算规则与物理前提

用户希望在可复用的温度和外场范围内，对同一条源轨迹通过重加权生成不同条件的候选统计量。因此预算不按每个温度或外场重新增加 **MD** 轨迹。对每帧保存的 OFF23 与 POLAR 基础能量，若

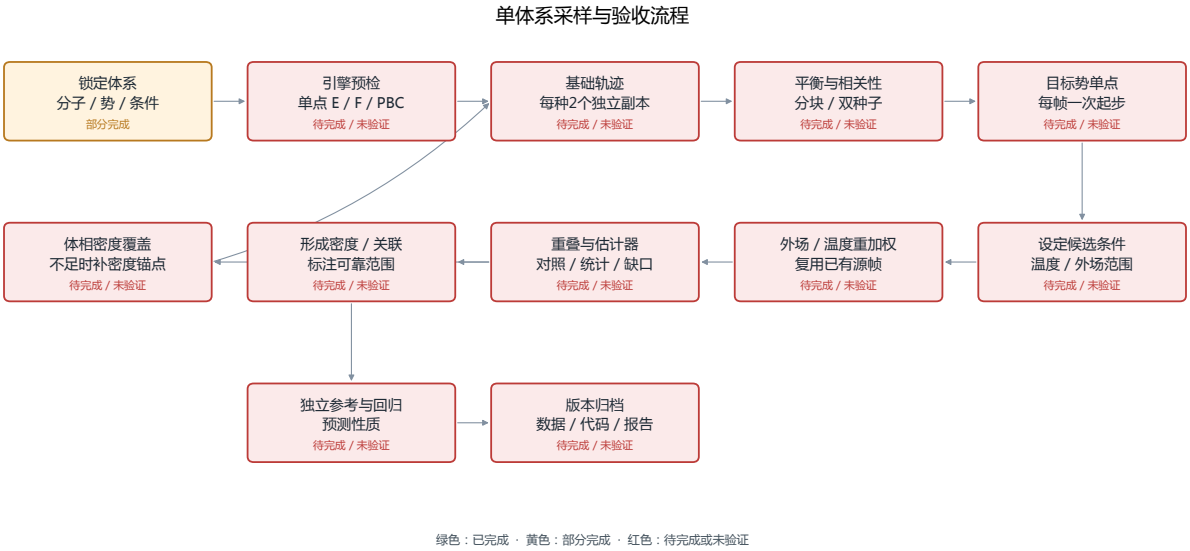


Figure 4: 单体系的计划采样、质量检查和结果归档。红色节点均为后续工作，箭头表示数据流，箭头不表示结果已通过。

目标外势可表示为独立的逐帧外场能，便可后处理不同温度和场强；同一帧的目标能量不必因每个后处理温度重复算。

不过，2 倍权重指数波动线只是当前水样本的对照条件，不能证明密度、g 或 c_1/c_2 的预测误差达到要求。已有水轨迹去除前 20 帧后的目标权重 ESS 约 1.20，没有独立 POLAR 长轨迹；因此应把它作为候选扫描范围，不是六分子无条件复用的验收范围。POLAR 的自洽电荷与极化若随外场变化，目标能量是 $U_H(x;V)$，必须核验并可能对每个场重新评估；简单叠加固定偶极场不是全极化结果。

固定 N, V 的单条 NVT 轨迹总粒子数和平均密度固定；重加权不同外场可以改形状，但不能自动创造不同平均密度的均匀体相样本。已有一条水 500 ps 轨迹呈分层，且 `test` 仓库没有对应可直接续跑的完整 restart；它先按诊断数据保留，是否能作为所需体相锚点和续跑起点需核实。

5.2 对照三篇论文：还需要补多少

为避免把生成剖面数当作独立轨迹数，先把论文给出的样本单元与本项目的候选方案分开：

方法	原文数据单元	若机械对齐六分子	当前条件
PNAS	每流体/势 500–1000 个随机场 MD 模拟；每个至少 1 ns 生产	3000–6000 个场条件剖面的数量级	可先尝试同一基础轨迹重加权生成候选；彼此相关，不能算作 3000 条独立 MD
PRL	LJ 体相 800 组密度与 g/c_2 训练数据	若每种分子都要求 800 个体相密度，则为 4800 组	单个 NVT 基础盒只有一个平均密度；3 密度/种只有 18 组候选，尚未认证
JCTC	超临界 CO_2 位置–取向密度；SI 描述 320 组剖面	若按每种 320 组的示例估算，则 1920 组	当前非线性分子的取向、统计和模型误差未验收，不能认定已有 1920 组合格标签

上表中的 3000–6000、4800 和 1920 是将论文单体系数量机械相乘得到的对齐情景，不是证明每种分子必须达到的数量。当前本周两个仓库没有给出六种分子合格的目标 c_1/c_2 状态清单，不能从原始帧数精确扣除已有标签；因此无法声称“还差多少个合格标签”。通过重加权生成多个温度或外场剖面可减少额外 MD，但准确性和状态覆盖必须逐条件测试，且共用轨迹带来统计相关。

在 300 K、无附加场的水例上，保留 481 帧时 $\mathrm{sd}(\ln q) \simeq 13.224$；已有的 260 K、$0.25\,\mathrm{V/Å}$ 是固定偶极代理在同一源轨迹上的后处理，整体波动约原来的 2.106 倍。该比较线不包含完整 POLAR 自洽极化、未给出密度误差，且不能直接外推至其他分子。即使满足这条线，也不能因此认定独立参考验证已完成。

以来源温度 $T_0 = 300\,\mathrm{K}$ 计算目标温度 T 和目标附加外场时，

$$\ln q(x) = \beta_0 U_L(x) - \beta_T[U_H(x) + U_{\mathrm{ext}}(x)] + C. \tag{4}$$

C 是构型无关的常数；不能只把源轨迹的 β_0 换成 β_T 而遗漏源温度项。若同温源和目标有相同外场则该场在能量差中抵消。累计有多少个不同候选场/温度只决定后处理的工作量，不自动决定所需的独立源轨迹数量。

5.3 最低探索：6 条基础轨迹

如果每种分子暂只设一个基础状态、一个副本，理论上只需 6 条源势轨迹；每条在充分平衡后以约 $1\,\mathrm{ns}$ 为首轮生产目标。若已有水轨迹与目标状态完全匹配且能可靠续跑，则是其余 5 种各 1 条新轨迹加水轨迹延长；当前水数据不满足这个假设的证据，因此不能预先把它抵扣为完整体相 1 ns。单轨迹仅供筛查，不能估计独立副本之间的重现性。

5.4 建议基础批：12 条基础轨迹

为衡量统计重复性，每种分子选择一个适用的基础密度与 300 K、各做 2 条独立副本。每条预算 $200\,\mathrm{ps}$ 预平衡、$1\,\mathrm{ns}$ 生产；如按每 $1\,\mathrm{ps}$ 保存，则每条约 1000 原始帧。每种 2 条、$2.4\,\mathrm{ns}$，六种共 12 条、$14.4\,\mathrm{ns}$ 和约 12,000 帧。温度及外场的候选剖面全部先从这些基础轨迹复用，不额外乘以外场数。现有水轨迹的 2 倍波动线不等于可复用性认证；对每一候选目标需要检查密度与关联估计误差、重叠和独立参考。

5.5 目标参考另算：建议 6 条短对照

为了判断复用得到的统计量是否接近目标，建议优先为每种分子选一个能进入目标势采样的状态，增加 1 条独立 POLAR 参考轨迹。若只作初步检查，每条先按 0.1 ns 平衡加 0.2 ns 生产记账：6 条共 1.8 ns。它们属于目标参考，与上述 12 条源轨迹不是同一条，也不按每个场和温度重复；是否足够仍取决于各物理量的相关时间和精度要求。未计这 6 条时是 12 条，建议参考一并实施时为 **12** 条源轨迹 **+ 6** 条目标短对照 **= 18** 条计划轨迹。具体 POLAR 工时尚未在计划硬件和六分子条件下测速。

5.6 体相覆盖不足时：36 条基础轨迹

若后续 $g/S \to c_2$ 与统一泛函需要每种 3 个独立平均密度锚点，每个锚点 2 个独立副本，则每种 6 条基础轨迹、$7.2\,\mathrm{ns}$、约 6000 个原始生产帧；六种为 36 条、$43.2\,\mathrm{ns}$、约 36,000 帧。这是可调整的探索预算，不是证明 3 个密度足以训练泛函的结论。

分子	基础状态	副本	基础轨迹	基础/ns	扩展轨迹	扩展/ns
H_2O	1	2	2	2.4	6	7.2
NH_3	1	2	2	2.4	6	7.2
CH_4	1	2	2	2.4	6	7.2
C_2H_4	1	2	2	2.4	6	7.2
C_2H_6	1	2	2	2.4	6	7.2
CO_2	1	2	2	2.4	6	7.2
合计	6	–	12	14.4	36	43.2

基础 / 扩展分别对应每分子 1 / 3 个基础密度，均按每状态 2 副本；各条时长是 0.2 ns 预平衡加 1 ns 生产。对不同温度和外场生成的再加权曲线，它们来自相同帧、彼此统计相关；500 条曲线不是 500 条独立轨迹。训练与验证应按源轨迹、密度、分子和外场分组，避免把共享构型泄漏到训练和测试两侧。

5.7 目标单点次数与并行资源

每个用于重加权的时刻要有同一构型的目标能量：若 12 条基础轨迹每条 1000 帧都评分，需要约 12,000 次目标单点；若 36 条扩展轨迹全部评分，需要约 36,000 次。每条只评分 100 帧则分别为 1200 或 3600 次，但重加权只能使用已评分的那 100 帧。不同温度如果势函数本身不随温度改变，可以复用相同帧的基础能量；场依赖自洽极化与力辅助估计则可能需要新增目标场能或力计算，不能将其成本设为零。

真实速度参考仅有 OFF23、1152 原子水、Symmetrix/LAMMPS、FP32、1 fs：生产日志 500,000 步耗时 68,990.2 s，即 7.247 步/s 或 38.33 GPU 时/ns [6]；日志未能确认 GPU 型号。仅作预算情景：假设六种分子每步都与这个水例一样快，12 条基础轨迹约 $14.4 \times 38.33 = 552$ GPU 时、三卡理想并行约 7.7 天；36 条扩展约 $43.2 \times 38.33 = 1656$ GPU 时、三卡约 23.0 天。该假设没有测过其他分子、盒子和势，未含目标单点、等待或重试；真正预算必须按每种分子和实际硬件短跑计时后替换。

如果温度或外场的目标分布缺乏重叠、独立参考不符或统计误差超出事先设定的用途容差，针对这些失败条件增加源势、目标势或中间态轨迹；不预先对每一个网格点重复跑。每个分子的状态、势、误差门槛和评估结果都要保存，不应把水的“2 倍波动范围”推广为另外五种分子的已验证范围。

6 数据验收与后续执行顺序

1. 核验 OFF23 引擎/重算同帧能量与力、邻居表、目标势模型哈希和长程配置；维持未修前诊断与修正结果的版本对应。
2. 选择每种物质可证明适用的势和阶段一状态；完成独立副本、时间步和盒大小检查，记录真实吞吐、失败率与观测量的相关时间。
3. 对均匀体相，检查 $g(r)$ 尾部、$S(k)$ 低波数与有限尺寸；对不均匀体系保存位置依赖密度/关联，不直接套均匀 OZ。
4. 从随机场密度建立 PNAS 形式的潜变量 c_1 数据，从均匀体相 g/S 构建适用的 c_2 监督；留出场形和状态。
5. 再评估包含分子信息 ξ 的统一模型，分别做留状态、留外场、留分子实验，并用独立参考比较密度、$g(r)$、$S(k)$、相平衡与 cDFT 迭代。新分子没有训练标签时，泛化只能由留分子实验验证。

7 归档与复现入口

交互文件 `workbench/index.html` 离线打开，点击节点查看说明，拖动和修改后导出 JSON。静态流程的 PDF/SVG/PNG 及 Python 源码在 `figures/`；预算和结果 CSV/JSON、证据哈希及原始仓库路径在归档目录。生成的分子封面图是概念示意，不代表六分子混合体系已被模拟。

References

[1] A. T. Bui and S. J. Cox, A unified machine-learning framework for ab initio multiscale modeling of liquids, PNAS 123, e2610049123 (2026). 10.1073/pnas.2610049123.

[2] J. Dijkman et al., Learning Neural Free-Energy Functionals with Pair-Correlation Matching, PRL 134, 056103 (2025). 10.1103/PhysRevLett.134.056103.

[3] Symmetrix-Polar, *Path B six-molecule teacher smoke*, 2026-10-22, source snapshot 68f08d1.

[4] Symmetrix-Polar, *Bulk + gas dataset rebuild*, 2026-10-25, source snapshot 68f08d1.

[5] Symmetrix-Polar, *Sampling pipeline audit*, 2026-10-23, source snapshot 68f08d1.

[6] Test repository, `log.production_1fs`, production run at 300 K, source snapshot 65a0423.

[7] J. Yang et al., High-Dimensional Operator Learning for Molecular Density Functional Theory, JCTC 21, 5905–5915 (2025). 10.1021/acs.jctc.5c00484; SI, Sec. S1.